

Predicción de Riesgo de Accidentes de Tráfico mediante Redes Neuronales

Ana Karen Toxqui Toxqui, *MMOP, CIMAT - Aguascalientes,*

Abstract—Este artículo presenta una implementación detallada de un modelo de predicción de riesgo de accidentes de tráfico basado en redes neuronales LSTM (Memoria a Corto y Largo Plazo). La motivación detrás de este enfoque radica en la complejidad de predecir directamente la ocurrencia de accidentes de tráfico debido a factores diversos y, en ocasiones, impredecibles.

Index Terms—Predicción de Accidentes de Tráfico, Redes Neuronales LSTM, Seguridad Vial, Riesgo de Accidentes, Aprendizaje Profundo, CNN, Prevención de Accidentes, Datos Espacio-Temporales.

I. INTRODUCCIÓN

EL desarrollo de los entornos urbanos ha provocado un incremento en el número de vehículos que existen en las ciudades generando así retos importantes para la seguridad vial, entre ellos la prevención de accidentes de tráfico es uno de los más importantes ya que causa pérdidas económicas y humanas. La complejidad inherente a la predicción directa de eventos de este tipo, el aumento en el número de datos de tráfico y el avance en técnicas de aprendizaje profundo, ha llevado al desarrollo de enfoques innovadores que buscan abordar este problema de manera proactiva. En este contexto, el presente artículo introduce un método avanzado de predicción de riesgo de accidentes de tráfico, basado en el empleo de redes neuronales LSTM (Memoria a Corto y Largo Plazo).

La singularidad de este enfoque radica en su capacidad para capturar patrones temporales en secuencias de datos, así como para incorporar información geográfica que enriquece la predicción. El modelo propuesto, surge como una herramienta que aprovecha la memoria a largo plazo de las LSTM y la flexibilidad de las capas totalmente conectadas para ofrecer predicciones precisas y contextualmente ricas.

En este artículo se describe la estructura y funcionamiento del modelo, se pretende que el modelo prevé la frecuencia de accidentes en entornos geográficos discretizados, además aborda la decisión de emplear capas LSTM sobre otras arquitecturas y justificaremos la inclusión de información geográfica como factor determinante en la mejora de la precisión del modelo. La implementación del modelo abarcará desde la preparación de datos hasta la evaluación del modelo, proporcionando una guía completa para la aplicación práctica de esta metodología.

El artículo se organiza de la manera siguiente: En la Sección 2 se hace mención algunos trabajos previos relacionados con la

identificación y prevención de accidentes de tráfico mediante técnicas de Machine Learning y Deep Learning. La Sección 3 describe el tratamiento que se le dio a los datos, en la Sección 4 se describe con detalle el modelo implementado, posteriormente en la Sección 5 se muestra la metodología implementada, más adelante en la Sección 6 se muestran los resultados y finalmente en la Sección 7 se dan el análisis y conclusiones de este trabajo.

II. TRABAJOS RELACIONADOS

La importancia de la predicción de accidentes vehiculares a motivado múltiples investigaciones, en las cuales se utilizan diversas técnicas de aprendizaje automático para el análisis y pronóstico de accidentes de tráfico. Algunos de los métodos más utilizados incluyen redes neuronales artificiales, algoritmos de árboles de decisión, redes neuronales convolucionales, redes de memoria a corto plazo, entre otros. Además, se han empleado algoritmos de clustering, reglas de asociación y procesamiento de lenguaje natural.

Estos esfuerzos reconocen en su mayoría que uno de los desafíos futuros en la predicción de accidentes de tráfico es la incorporación de fuentes de datos heterogénea como la utilización de datos geoespaciales, información sobre el volumen de tráfico, datos de redes sociales y otros tipos de datos para mejorar la precisión y exactitud de los análisis y predicciones. A su vez se entiende la complejidad inherente del tema, que incluye el comportamiento humano y la psicología por lo que actualmente se están realizando investigaciones para superar esta limitación, como el uso del análisis de sentimientos y estrés extraídos de datos de redes sociales para mejorar la detección de eventos de tráfico.

III. TRATAMIENTO DE DATOS

La recolección y tratamiento de datos es una parte esencial en la construcción del modelo de predicción de accidentes de tráfico, debido a la complejidad del problema se realizó un proceso de tratamiento de datos para capturar las complejidades temporales y espaciales asociadas.

Los datos usados en el modelo fueron obtenidos de la base de datos "Crash Vehicle Data (SOR)" mantenida por el Departamento de Transporte de Iowa, la cual contiene datos de accidentes de vehículos de los últimos 10 años. Estos datos contienen un total de 1472144 registros, están abiertos al público y se pueden acceder mediante el sitio web de Análisis y datos de seguridad del tráfico (www.iowadot.gov/tsda),




Fig. 1. Mapa de calor de una matriz S generada por la discretización de los datos

cada registro contiene la información del punto exacto del accidente en coordenadas latitud y longitud así como el día y hora en el que ocurrió el accidente.

Para la aplicación de los datos dentro del modelo propuesto fue necesario construir una estructura de datos adecuada. Para esto se realizó en primera instancia una discretización de datos en el espacio y tiempo. La resolución temporal usada fue de un día, para la resolución espacial se tomaron las coordenadas máximas y mínimas tanto en latitud como en longitud y se construyó una cuadrícula uniforme de tamaño 15×15 , generando así matrices por cada día, S , cuyos elementos $S_{r,t}$ es el recuento de accidentes de tráfico ocurridos dentro región r , en el día t , como se muestra en la Figura 1. Este proceso permite la aplicación de una ventana deslizante a lo largo del tiempo que genera secuencias de accidentes, permitiendo al modelo aprender patrones y tendencias temporales. Este enfoque refleja la importancia de considerar la evolución del riesgo de accidentes a lo largo del tiempo, proporcionando al modelo la capacidad de capturar variaciones estacionales y patrones recurrentes.

Posteriormente las secuencias temporales se transforman en tensores Numpy, y se realiza una distinción entre las secuencias de accidentes y las coordenadas geográficas. Este formato tensorial es esencial para facilitar el entrenamiento del modelo, ya que las redes LSTM son especialmente adecuadas para trabajar con datos secuenciales. Este proceso de tratamiento de datos no solo estructura la información de manera efectiva para el modelo, sino que también permite al sistema capturar la dinámica temporal y geoespacial inherente al riesgo de accidentes de tráfico.

IV. MODELO DE PREDICCIÓN DE ACCIDENTES DE TRÁFICO

El modelo de aprendizaje profundo implementado en este trabajo se diseñó para abordar la complejidad temporal y espacial asociada con la predicción de riesgo de accidentes de tráfico.

El modelo se alimenta con dos fuentes de entrada distintas, en primer lugar se tiene las secuencias temporales de accidentes, generadas durante el tratamiento de datos, estas




Fig. 2. Arquitectura de red usada en el modelo de predicción de accidentes

secuencias representan el histórico de accidentes en una ubicación específica a lo largo del tiempo. Cada secuencia encapsula la evolución temporal de los accidentes durante un período específico, como los últimos 7 días. Al introducir estas secuencias en las capas LSTM, el modelo tiene la capacidad de aprender patrones, correlaciones temporales y tendencias en la frecuencia de accidentes. La segunda entrada comprende las coordenadas geográficas, es decir, la latitud y longitud de la región que se está prediciendo. Este componente geoespacial agrega una dimensión crítica a la predicción, permitiendo al modelo contextualizar el riesgo de accidentes en función de la ubicación geográfica.

Para el modelo se optó por usar cuatro capas LSTM, diseñadas para capturar las dependencias temporales en las secuencias de accidentes, cada una con 500 unidades y funciones de activación tangente hiperbólica (\tanh). Durante la fase de entrenamiento, las capas LSTM procesan las secuencias temporales, capturando las dependencias temporales y extrayendo características temporales significativas. La arquitectura en capas LSTM apiladas permite al modelo aprender a reconocer patrones complejos y secuencias temporales, lo que es crucial para la predicción precisa del riesgo de accidentes.

Después de procesar las secuencias temporales, se emplean capas totalmente conectadas para integrar la información geográfica. Las capas posteriores a las LSTM incluyen una capa con 200 unidades y activación ReLU, seguida de otra capa con 200 unidades y dropout para prevenir el sobreajuste. Se añaden dos capas adicionales con 100 y 200 unidades, respectivamente, ambas con dropout. La concatenación de la salida de las capas LSTM con las coordenadas geográficas crea una representación enriquecida y contextualizada que captura tanto la evolución temporal como la variabilidad espacial del riesgo de accidentes. La capa de salida es una capa Dense con una única unidad y activación lineal, que produce la predicción final del riesgo de accidentes de tráfico, la arquitectura del modelo se puede observar en la Figura 2.

Se utiliza el optimizador SGD (Stochastic Gradient Descent) con una tasa de aprendizaje de 0.005 y momento de 0.9. El modelo se compila con una función de pérdida de error cuadrático medio (MSE) y métricas adicionales, como el error absoluto medio (MAE). En resumen, la arquitectura del modelo se distingue por su combinación de capas LSTM para la captura de información temporal y capas totalmente conectadas para integrar información geográfica. Esta estructura, respaldada por técnicas de regularización como el dropout, proporciona un marco robusto para la predicción precisa del riesgo de accidentes de tráfico.

V. METODOLOGÍA

Se inició cargando el conjunto de datos desde un archivo CSV que contiene información sobre accidentes de tráfico, de los datos originales se recuperaron las coordenadas, el id del accidente y las fechas que se convirtieron al formato datetime para facilitar su manipulación temporal, con esto se generaron las secuencias temporales de accidentes de la manera siguiente; para cada ubicación única se utilizó una ventana deslizante a lo largo del tiempo con lo que se capturó la evolución temporal de los accidentes y permitió al modelo aprender patrones a lo largo del tiempo. Más adelante las secuencias generadas se transformaron en tensores Numpy, y se realizó una separación entre las secuencias de accidentes y las coordenadas geográficas. Este formato tensorial fue esencial para el modelo.

Posteriormente se dividieron los datos en conjuntos de entrenamiento, validación y prueba utilizando la función train test split, esto con el fin de asegurar la evaluación del modelo en conjuntos de datos independientes. Los datos de entrada, especialmente las secuencias temporales, se normalizan utilizando el escalador Min-Max, esto para asegurar que el modelo aprenda de manera consistente independientemente de las escalas de los valores.

Todo el modelo se hizo mediante la paquetería de TensorFlow a la cual se le hizo la adecuación correspondiente para poder usarla a través de GPU y así aprovechar la potencia de procesamiento paralelo y acelerando el entrenamiento del modelo en grandes conjuntos de datos. Con esto se definieron las capas del modelo, con capas LSTM para procesamiento temporal y capas totalmente conectadas para integrar información geográfica, así se compiló el modelo utilizando un optimizador SGD, una función de pérdida MSE y métricas adicionales, para la compilación se establecieron las configuraciones de entrenamiento y evaluación del modelo.

El modelo se entrenó utilizando los conjuntos de datos de entrenamiento y validación. Durante el entrenamiento, el modelo ajusta sus pesos para minimizar la función de pérdida, aprendiendo patrones y relaciones en los datos. Finalmente el rendimiento del modelo se evaluó en el conjunto de prueba. Se calcularon métricas como la pérdida, el error absoluto medio y el error cuadrático medio para evaluar la precisión y generalización del modelo.

VI. RESULTADOS

El análisis de rendimiento del modelo en el conjunto de prueba proporciona información sobre su capacidad predictiva en situaciones del mundo real. Los resultados obtenidos tras la evaluación son los siguientes:

La pérdida, medida por la función de error cuadrático medio (MSE), alcanzó un valor de 3.56 en el conjunto de prueba. Esta métrica cuantifica la diferencia promedio entre las predicciones del modelo y los valores reales de accidentes. En este caso, indica que, en promedio, las predicciones del modelo están desviadas por aproximadamente 3.56 unidades.

El error absoluto medio, una medida de la magnitud promedio de los errores de predicción, se registró en 67.63, lo que significa que, en promedio, las predicciones del modelo pueden desviarse por aproximadamente 67.3 unidades con respecto a los valores reales. Por otro lado, el error cuadrático medio, que penaliza los errores más grandes de manera más significativa, registro 5560, lo que indica que hay algunos errores de predicción que contribuyen significativamente a la función de pérdida total.

VII. ANÁLISIS Y CONCLUSIONES

La aplicación del modelo propuesto para la predicción de riesgo de accidentes de tráfico ofrece perspectivas valiosas sobre la utilidad de las redes neuronales LSTM en este contexto específico. Particularmente se tiene que las capas LSTM permiten al modelo discernir tendencias, estacionalidades y variaciones temporales, mejorando significativamente la capacidad de predicción en comparación con enfoques más simples. Sin embargo como todo modelo depende mucho de la calidad y cantidad de datos disponibles para el entrenamiento del modelo, en este modelos los datos se encontraban agrupados en las zonas de mayor actividad de la ciudad de Iowa, lo que peso en el rendimiento del modelo. Una colección de datos más amplia sin duda mejoraría el rendimiento del modelo. Por otro lado la inclusión de coordenadas geográficas enriqueció la capacidad del modelo para contextualizar el riesgo de accidentes en función de la ubicación. Haciendo que el modelo no solo prediga la frecuencia de accidentes, sino que también ajusta sus predicciones según las características específicas de cada región, mostrando una adaptabilidad valiosa.

Es necesario mencionar que el modelo depende en gran parte de la longitud de secuencia temporal que se utiliza para entrenar el modelo, experimentar con diferentes longitudes podría ofrecer una predicción más precisa. En esta ocasión no se realizó una exploración extensa de los diferentes parámetros involucrados en el modelo, como trabajo a futuro se propone ajustar la tasa de aprendizaje, el tamaño de las capas LSTM y otros hiperparámetros podría ser un área de investigación futura, así como la incorporación de información adicional tanto geográfica, temporal como de los accidentes en si mismos.

Finalmente se concluye que el modelo es un buen acercamiento al problema, sin embargo, se reconoce la necesidad continua de refinamiento y ajuste, especialmente en la selección óptima de parámetros y la consideración de factores adicionales.

VIII. BIBLIOGRAFÍA

Gutierrez-Osorio, C., & Pedraza, C. (2020). Modern data sources and techniques for analysis and forecast of road accidents: A review. *Journal of Traffic and Transportation Engineering (English Edition)*, 7(4), 432–446. <https://doi.org/10.1016/j.jtte.2020.05.002>

Ren, H., Song, Y., Wang, J., Hu, Y., & Lei, J. (2018). A deep learning approach to the citywide traffic accident risk prediction. 2018 21st International Conference on Intelligent Transportation Systems (ITSC).

Shaik, M. E., Islam, M. M., & Hossain, Q. S. (2021). A review on neural network techniques for the prediction of road traffic accident severity. *Asian Transport Studies*, 7(100040), 100040. <https://doi.org/10.1016/j.eastsj.2021.100040>